

Análise de Texto em Redes Sociais usando combinação de classificadores, meta-aprendizagem e/ou AutoML

Inscrito nº: 125225

¹Projeto de Pesquisa e Plano de Trabalho

1. Projeto de pesquisa

1.1. Introdução

Segundo pesquisa elaborada pelo Ministério dos Direitos Humanos e da Cidadania (MDHC), o Observatório Nacional dos Direitos Humanos comparou dados de 2017 a 2022 sobre discurso de ódio em ambiente virtual; mais de 293 mil denúncias foram registradas no período. Os crimes de ódio na internet chegaram a mais de 74 mil casos em 2022 – maior número desde 2017 – de acordo com dados registrados pela Central Nacional de Denúncias de Crimes Cibernéticos, da organização SaferNet. Os números constam no Observatório Nacional dos Direitos Humanos (ObservaDH), do Ministério dos Direitos Humanos e da Cidadania (MDHC). Lançado no mês passado, o ObservaDH reúne dados sobre direitos humanos disponíveis no país, com foco nas informações e indicadores estratégicos sobre os grupos sociais e os temas prioritários do MDHC.

Entre 2017 e 2022, a plataforma revela um total de 293,2 mil denúncias de crimes de ódio motivados por preconceito ou intolerância contra grupos ou indivíduos por sua identidade ou orientação sexual, gênero, etnia, nacionalidade ou religião. Estes crimes podem assumir diversas formas na internet, como ofensas, ameaças, injúrias, difamações, incitações à violência, apologias ao crime e divulgação de imagens ou vídeos humilhantes.

Considerando todo o período de 2017 a 2022, o tipo de crime de ódio mais denunciado na Central da SaferNet foi o de apologia a crimes contra a vida (76,1 mil), seguido da misoginia (74,3 mil no total). Ainda durante o período, a misoginia foi o crime de ódio que mais cresceu, passando de 961 denúncias, em 2017, para 28,6 mil em 2022, representando um aumento de quase 30 vezes. Durante os cinco anos também foram registradas 45,6 mil denúncias de racismo, 32,6 mil casos de neonazismo, 28,3 mil de LGBTfobia, 25,9 mil ocorrências de xenofobia e 10,2 mil de intolerância religiosa. [R.O 2024].

1.2. Problemática e Justificativa

Além da literatura é possível ver que esse tópico já foi plano de fundo das ficções da série “Os Simpsons”. No décimo episódio da vigésima sétima temporada, intitulado: “The Girl Code”, Lisa Simpson lança uma ideia de aplicativo que pode prever os efeitos negativos de uma postagem em redes sociais. O aplicativo alerta às pessoas o que vai acontecer se postarem certas coisas. A experiência funciona quando Bart Simpson, prestes a compartilhar um vídeo humilhante do Diretor da Escola Elementar de Springfield, Seymour Skinner, recebe um aviso que essa postagem poderia causar uma detenção de 5 semanas [IMDB].

O trabalho de [Omran et al. 2023] visa detectar e mitigar discurso de ódio em mídias sociais, particularmente em plataformas como o Twitter (X), apesar de ter um impacto social significativo, é uma tarefa bastante desafiadora, ao utilizar de um *trade-off*

entre simplicidade, facilidade de implementação, eficiência computacional e bons resultados. Mesmo utilizando algoritmos simples, como *Naive Bayese Decision Tree*, bons resultados são encontrados.

1.3. Relevância e Impacto

Esta proposta, de caráter social e de assegurar os direitos humanos, torna uma ferramenta tanto de base de pesquisa, quanto de produto que é bastante útil no combate a práticas de assédio e violência em qualquer tipo de ambiente virtual.

1.4. Referencial Teórico

A Sentiment Analysis Benchmark for Automated Machine Learning Applications and a Proof of Concept in Hate Speech Detection, Este artigo aborda o desafio de fornecer conjuntos de dados padronizados para análise de sentimentos em inglês e propõe um *benchmark* de AutoML [Silva et al. 2023].

A survey on hate speech detection and sentiment analysis using machine learning and deep learning models Uso de aprendizado de máquina e aprendizado profundo para criar sistemas automatizados que podem efetivamente detectar discurso de ódio e conduzir análise de sentimentos, oferecendo soluções potenciais para abordar esse problema urgente. Este artigo de pesquisa fornece uma visão geral abrangente dos avanços recentes em detecção de discurso de ódio e análise de sentimentos [Subramanian et al. 2023].

1.5. Referencial Metodológico

Esta seção detalha ligeiramente os métodos, possíveis arquiteturas adotadas, conjuntos de dados utilizados e o foco prático da solução do problema definido neste documento.

1.5.1. Métodos

Conforme as técnicas dos trabalhos apresentados, recentemente as arquiteturas utilizadas pelos autores dos trabalhos relacionados são baseadas em algoritmos e modelos clássicos de aprendizado de máquina como: Support Vector Machines (SVM), Naive Bayes (NB), Decision Trees (DT), and Logistic Regression (LR). Porém, é muito válido, utilizar de arquitetura mais robustas como *Convolutional Neural Networks* (CNNs), *Recurrent Neural Networks* (RNNs) e outras baseadas em Transformers, tais como *BERT* e *GPT*, que além de conseguir detectar com eficácia termos e contextos tóxicos, pode também, sugerir uma adequação dos termos impróprios [Subramanian et al. 2023].

1.5.2. Dados

Uma listagem de conjunto de dados é apresentada em [Subramanian et al. 2023], porém, há base de dados maiores como do fórum Reddit, que possui comentários que quase dezenas de anos e que podem ser usados como conjunto de teste das arquiteturas classificadoras de conteúdo [Stuck In The Matrix]. No artigo escrito por [Silva et al. 2023], um *benchmark* é executado utilizando vários conjuntos de dados de textos não-sintéticos e algumas ferramentas de Aprendizado de Máquina Automático (AutoML) com o propósito de detectar discurso de ódio para apresentar.

1.5.3. Cenário

A proposta deste trabalho pode ser aplicada em textos reais em páginas públicas de redes sociais, formulários com conteúdo e texto para comentários abertos aplicados a colaboradores da pesquisa e publicações sintéticas para validação.

2. Plano de Trabalho

As etapas de aquisição de dados, modelagem, execução, experimentação e escrita da proposta estão listadas a seguir:

Captura dos Dados Um experimento inicial pode ser realizado utilizando os conjuntos de dados mencionados neste trabalho, variando as ferramentas de *AutoML*, adicionando arquiteturas, modelos e algoritmos não citados nas referências bibliográficas, a fim de ter uma fonte de resultados abrangentes e unificados.

Extração de novas informações Com conjuntos de dados distintos dos mencionados nos trabalhos de referência, pode-se criar novos exemplares de fóruns abertos, de preferência escritos em português.

Criação de uma arquitetura própria É proposta uma arquitetura que utiliza das nuances e técnicas do estado-da-arte que possa gerar melhores resultados e sugestões de escrita.

Referências

IMDB. "The Simpsons" The Girl Code (TV Episode 2016) 6.6 — Animation, Comedy — imdb.com. <https://www.imdb.com/title/tt5148632/>. [Accessed 02-12-2024].

Omran, E., Al Tararwah, E., and Al Qundus, J. (2023). A comparative analysis of machine learning algorithms for hate speech detection in social media. *Online Journal of Communication and Media Technologies*, 13(4):e202348.

R.O (2024). Incitação à violência contra a vida na internet lidera violações de direitos humanos com mais de 76 mil casos em cinco anos, aponta ObservaDH — gov.br. <https://www.gov.br/mdh/pt-br/assuntos/noticias/2024/janeiro/incitacao-a-violencia-contra-a-vida-na-internet-lidera-violacoes-de-d> [Accessed 02-12-2024].

Silva, M. C. R., Oliveira, V. A. d., and Pardo, T. A. S. (2023). A sentiment analysis benchmark for automated machine learning applications and a proof of concept in hate speech detection. *Anais*.

Stuck In The Matrix, Watchful1, R. Reddit comments/submissions 2005-06 to 2024-06.

Subramanian, M., Easwaramoorthy Sathiskumar, V., Deepalakshmi, G., Cho, J., and Manikandan, G. (2023). A survey on hate speech detection and sentiment analysis using machine learning and deep learning models. *Alexandria Engineering Journal*, 80:110–121.