

Detecção de Assédio em Imagens Utilizando Técnicas de Aprendizado Profundo

Inscrito nº: 115350

¹Projeto de Pesquisa e Plano de Trabalho

1. Projeto de pesquisa

1.1. Introdução

Segundo pesquisa elaborada pela Folha de São Paulo, crimes sexuais aumentaram no último ano. Segundo o Anuário Brasileiro de Segurança Pública divulgado em 20 de julho de 2023 pelo Fórum Brasileiro de Segurança Pública, indica que, entre 2021 e 2022, houve um crescimento no número de casos de assédio sexual, importunação sexual, perseguição, violência psicológica e divulgação de cenas sexuais sem consentimento.

Em 2022, o Brasil registrou um total de 6.114 casos de assédio sexual. Isso equivale a uma ocorrência do tipo a cada uma hora e 25 minutos. Em comparação com o ano anterior, houve um aumento de 49,7% desses crimes. Em 2021, esse número era de 5.202 [Folha 2023].

No meio acadêmico, pesquisas recentes utilizam de conteúdos textuais como base de detecção de evidência de tipos de abusos e assédios em redes sociais. A listagem que segue, agrupa alguns trabalhos publicados que promovem soluções de identificação de importunação sexual:

Sexual *Sexual harassment detection using machine learning and deep learning techniques for bangla text*[Islam et al. 2023];

Bullying *A review on deep-learning-based cyberbullying detection.* [Hasan et al. 2023], *Classification of virtual harassment on social networks using ensemble learning techniques* [Azeez and Fadhal 2023] e *Cyberbullying detection on twitter using deep learning-based attention mechanisms and continuous bag of words feature extraction* [Fati et al. 2023]

Como motivador, os trabalhos acima listados servem de guia de qual a problemática atual, a detecção, classificação e reconhecimento de atividades que ferem o respeito de outras pessoas.

1.2. Objetivo

Propor um modelo de aprendizado profundo que detecte comportamentos de assédio em imagens naturais vindas de dispositivos de captura e identifique detalhes conforme a área de toque na vítima.

1.3. Problemática e Justificativa

Essas pesquisas recentes visam apenas dados textuais e envolvem, principalmente, problemas de classificações binárias, se o conteúdo textual é ou não ofensivo. A proposta apresentada neste documento visa melhor identificar possíveis comportamentos invasivos por meio de imagens, classificando não apenas a existência de um toque, como o local onde a vítima foi tocada.

Além da contribuição dos trabalhos relacionados, existe uma possibilidade na identificação do abusador, do detalhamento do possível abuso e da utilização de diferentes bases de dados na utilização de aprendizado de modelos de aprendizado profundo. O trabalho apresentado em [Islam et al. 2023] nos fornece um ramo adicional para a motivação nesta proposta.

1.4. Relevância e Impacto

Esta proposta, de caráter social e vinculado à segurança pública, torna uma ferramenta tanto de base de pesquisa, quanto de produto que é bastante útil no combate a práticas de assédio e violência em qualquer tipo de ambiente monitorado.

1.5. Referencial Teórico

Esta seção lista alguns trabalhos recentes que motivaram a escrita deste projeto e que abordam: detecção, classificação de imagens vindas de câmeras de vídeo, imagens naturais, confirmando a existência de violência ou assédio:

A deep-learning approach to early identification of suggested sexual harassment from videos, utiliza de mecanismos de detecção de conteúdo de imagens como *Google Cloud Vision* e *Clarifai*, associado a um conjunto de dados próprio criado a partir de várias cenas de filmes. Essas cenas são classificadas como assédio sexual, abuso sexual ou violência sexual e exportadas no formato *PASCAL VOC 1.1* [Shetye et al. 2023].

Violence detection using deep learning, objetiva desenvolver um sistema de análise automática para detecção da presença de violência e não-violência utilizando técnicas de aprendizado profundo baseado em Rede Neural Convolucional (CNN) *MobileNet V2*, usada na extração de imagens de quadros de vídeo e redes Long Short-Term Memory (LSTM) para análise de movimento local em um vídeo [Shekokar et al.].

Violent activity detection through surveillance camera using deep learning, similar aos trabalhos anteriores, essa abordagem é baseada principalmente em conceitos de processamento de imagem usando diferentes redes neurais como *MobileNet-V2*, *ResNet50* e redes neurais baseadas em LSTM para combinar imagens ao vivo com as que foram utilizadas no treino do modelo existente. Este modelo será utilizado especificamente para detectar atividades criminosas como socos, chutes, tapas e violência com armas, e todas essas informações serão previamente armazenadas no banco de dados [Miah et al. 2023].

1.6. Referencial Metodológico

Esta seção detalha ligeiramente os métodos, possíveis arquiteturas adotadas, conjuntos de dados utilizados e o foco prático da solução do problema definido neste documento.

1.6.1. Métodos

Conforme as técnicas dos trabalhos apresentados, recentemente as arquiteturas utilizadas pelos autores dos trabalhos relacionados são baseadas em redes neurais recorrentes e redes convolucionais. É válido, também, utilizar das LCRN (Long-Term Recurrent Convolutional Networks), utilizadas em problemas de reconhecimento visual, associados à entradas e saídas variáveis no tempo [Donahue et al. 2015].

1.6.2. Dados

O conjunto de dados proposto nesse projeto é o [Fieraru et al. 2020] *FlickrCI3D*, um conjunto de dados de 11.216 imagens, com 14.081 pares de pessoas processados e 81.233 correspondências de superfície em 138.213 regiões de contato selecionadas, como mostra a Figura 2.




Figura 1. Cada assinatura de contato representa um conjunto de correspondências anotadas entre superfícies de contato de dois corpos humanos [FlickrCI3D].

Cada imagem possui uma assinatura e cada assinatura possui informações de localização, *bounding-boxes* e as zonas de contato, categorizados por 75 regiões conforme a representação *GHUM* e *SMPLX* [Fieraru et al. 2023, Pavlakos et al. 2019]

1.6.3. Cenário

A proposta deste trabalho pode ser aplicada em imagens naturais e também dar suporte a imagens de vídeo em qualquer tipo de ambiente monitorado, como nos trabalhos relacionados mencionados anteriormente.

2. Plano de Trabalho

As etapas de aquisição de dados, modelagem, execução, experimentação e escrita da proposta estão listadas a seguir:

Captura dos Dados A solicitação das bases de dados já foi feita e a extração das informações de *bounding boxes* já fazem parte das *features* que compõe a entrada de dados da rede.

Extração de informações das assinaturas Realizar mapeamento de cada área de contato e classificá-la conforme o nível de “intimidade” que se deve ter para haver a liberdade de toque. Um aperto de mão é “menos” inconveniente que um toque no pescoço. A transformação da área em 3d em pontos de identificação em 2d na imagem.



Figura 2. Transformação dos pontos em 3d numa imagem 2d. *Bounding-boxes* em vermelho. Áreas de contato, em pontos coloridos. Elaborado pelo autor, adaptado de [FlickrCI3D].

Criação de um modelo de CNN Criada a relação entre os *bounding-boxes*, os pontos de contato e o nível de “intimidade” de cada um dos pontos, é possível já criar um modelo de CNN que faça a detecção do toque e o nível do possível assédio.

Criação de um modelo de LRCN Com a arquitetura de CNN criada, o próximo passo é associar esse modelo a uma rede recorrente e executar mais testes em vídeos (filmes, transmissões esportivas, webcam de voluntários).

Referências

- Azeez, N. A. and Fadhal, E. (2023). Classification of virtual harassment on social networks using ensemble learning techniques. *Applied Sciences*, 13(7):4570.
- Donahue, J., Anne Hendricks, L., Guadarrama, S., Rohrbach, M., Venugopalan, S., Sankar, K., and Darrell, T. (2015). Long-term recurrent convolutional networks for visual recognition and description. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 2625–2634.
- Fati, S. M., Muneer, A., Alwadain, A., and Balogun, A. O. (2023). Cyberbullying detection on twitter using deep learning-based attention mechanisms and continuous bag of words feature extraction. *Mathematics*, 11(16):3567.
- Fieraru, M., Zanfir, M., Oneata, E., Popa, A.-I., Olaru, V., and Sminchisescu, C. (2020). Three-dimensional reconstruction of human interactions. In *The IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*.

- Fieraru, M., Zanfır, M., Oneata, E., Popa, A.-I., Olaru, V., and Sminchisescu, C. (2023). Reconstructing three-dimensional models of interacting humans. *arXiv preprint arXiv:2308.01854*.
- FlickrCI3D. Flickrci3d: Close interactions 3d.
- Folha (2023). Brasil tem alta de assédio, perseguição, importunação sexual e divulgação de imagens íntimas.
- Hasan, M. T., Hossain, M. A. E., Mukta, M. S. H., Akter, A., Ahmed, M., and Islam, S. (2023). A review on deep-learning-based cyberbullying detection. *Future Internet*, 15(5):179.
- Islam, M., Rahman, M., Ahmed, M. T., Islam, A. Z. M., Das, D., and Hoque, M. M. (2023). Sexual harassment detection using machine learning and deep learning techniques for bangla text. In *2023 International Conference on Electrical, Computer and Communication Engineering (ECCE)*, pages 1–6. IEEE.
- Miah, P., Haque, A. A., Imran, A. A., Hassan, M., and Rahman, R. (2023). *Violent activity detection through surveillance camera using deep learning*. PhD thesis, Brac University.
- Pavlakos, G., Choutas, V., Ghorbani, N., Bolkart, T., Osman, A. A. A., Tzionas, D., and Black, M. J. (2019). Expressive body capture: 3D hands, face, and body from a single image. In *Proceedings IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, pages 10975–10985.
- Shekokar, R., Padme, L., Mahale, H., and Tichkule, A. Violence detection using deep learning.
- Shetye, S., Maiti, A., Maiti, T., and Singh, T. (2023). A deep-learning approach to early identification of suggested sexual harassment from videos. *arXiv preprint arXiv:2306.00856*.